

Introduzione

Il problema affrontato in questo progetto è la *detection* di crateri su immagini di superfici planetarie. Data la natura di questo dataset, ho scelto di utilizzare **YOLOv1** (*You Only Look Once*), un modello di rilevazione degli oggetti preaddestrato, per addestrare una rete in grado di individuare i crateri.

Ho effettuato quattro diversi esperimenti con configurazioni differenti del modello, al fine di valutare l'impatto di parametri come il numero di epoche, il batch size, l'algoritmo di ottimizzazione e l'aggiunta di nuovi dati. Di seguito descrivo i vari tentativi, i parametri utilizzati e le osservazioni.

Primo Tentativo:

- **Epoche:** 50
- **Batch size:** 16
- **Descrizione:** In questo primo tentativo, ho utilizzato una configurazione standard con un numero moderato di epoche e un batch size di 16.

Secondo Tentativo:

- **Epoche:** 50
- **Batch size:** 16
- **Ottimizzatore:** Adam
- **Descrizione:** In questo secondo esperimento, ho introdotto l'ottimizzatore **Adam**, che tende a fornire una convergenza più veloce e una regolazione automatica del learning rate. L'uso di Adam è stato testato per vedere se migliorava l'accuratezza rispetto al modello base con SGD.

Terzo Tentativo:

- **Epoche:** 100
- **Ottimizzatore:** Adam
- **Descrizione:** Questo tentativo è simile al secondo, ma ho rimosso il batch size. Inoltre, ho raddoppiato il numero di epoche a 100 per vedere se una maggiore esposizione ai dati avrebbe potuto migliorare l'apprendimento. Tuttavia, essendo il numero di immagini nel dataset relativamente basso, questo approccio ha aumentato il rischio di **overfitting**.

Quarto Tentativo:

- **Epoche:** 100
- **Batch size:** 16
- **Learning rate:** $1e-3$
- **Ottimizzatore:** SGD
- **Descrizione:** In questo esperimento ho utilizzato nuovamente un numero di epoche elevato (100), ma con un batch size di 16 e un learning rate di $1e-3$. Ho scelto l'ottimizzatore **SGD** per vedere come si comporta con un learning rate più alto rispetto a quello usato in esperimenti precedenti.

Conclusioni

Tra i quattro modelli testati, il **quarto modello** è risultato essere quello che ha individuato correttamente il maggior numero di crateri, ottenendo le migliori prestazioni in termini di rilevazione. Tuttavia, uno dei principali problemi emersi durante l'addestramento è stato la **ridotta quantità di immagini** presenti nel dataset. Il numero limitato di esempi ha reso difficile l'addestramento di un modello che potesse generalizzare bene su nuovi dati. Una potenziale soluzione per affrontare questo problema potrebbe essere quella di implementare tecniche di **data augmentation**. L'augmentation dei dati, tramite operazioni come rotazioni, zoom, traslazioni o aggiustamenti di luminosità, potrebbe fornire al modello una varietà maggiore di esempi, aumentando la robustezza e la capacità di generalizzazione senza richiedere la raccolta di nuove immagini.

Inoltre, sarebbe interessante esplorare un approccio differente, come l'utilizzo di una rete **U-Net** per la segmentazione dei crateri. Questo approccio consentirebbe di mappare ogni pixel dell'immagine in base alla presenza o meno di un cratere, migliorando probabilmente l'accuratezza della rilevazione rispetto alla semplice individuazione delle coordinate. Tuttavia, non è stato possibile intraprendere questa strada poiché le annotazioni disponibili nel dataset sono fornite in formato `.txt` con le coordinate dei crateri, anziché come maschere di segmentazione.